


# Цель и данные

**Цель:** Разработка ML-модели для прогнозирования высокого потребления алкоголя.

## Данные

- 395 студентов, 22 признака
- Источник: HuggingFace Datasets
- Целевая: `high_alcohol`
- Дисбаланс: 89%/11%



Распределение целевой переменной

# Методы и модели

## Модели

- Logistic Regression
- **Random Forest**
- Gradient Boosting
- SVM
- KNN

## Метрики

Accuracy, Precision, Recall, F1, ROC-AUC

## Предобработка

- Label Encoding
- StandardScaler
- Стратификация 80/20


# Результаты моделей

Лучшая модель: Random Forest

Модель	Accuracy	F1-Score	ROC-AUC
Logistic Regression	0.91	0.72	0.92
<b>Random Forest</b>	<b>0.93</b>	<b>0.78</b>	<b>0.94</b>
Gradient Boosting	0.92	0.76	0.93
SVM	0.90	0.70	0.91
KNN	0.89	0.68	0.90

# Важность признаков

## Топ-15 факторов влияния:




**Вывод:** Социальная активность + академические проблемы =  
ключевые риски.

# Матрица ошибок и метрики

## Метрики на тесте


- Accuracy: 93%
- Precision: 93%
- Recall: 67%
- F1: 78%
- ROC-AUC: 0.94



# Выводы и применение

## Итоги

- Модель готова к внедрению
- $F1=0.78$ ,  $AUC=0.94$
- Основные факторы риска:
  - Социальная активность
  - Возраст (16-18 лет)
  - Академические проблемы



## Ограничение

Низкий Recall (67%) — может пропускать часть случаев

## Применение

- Скрининг групп риска
- Профилактические программы
- Фокус на студентов 16-18 лет